Fundamentos de la Ciencia de Datos
Cursada 2026
Práctico 7: Clustering

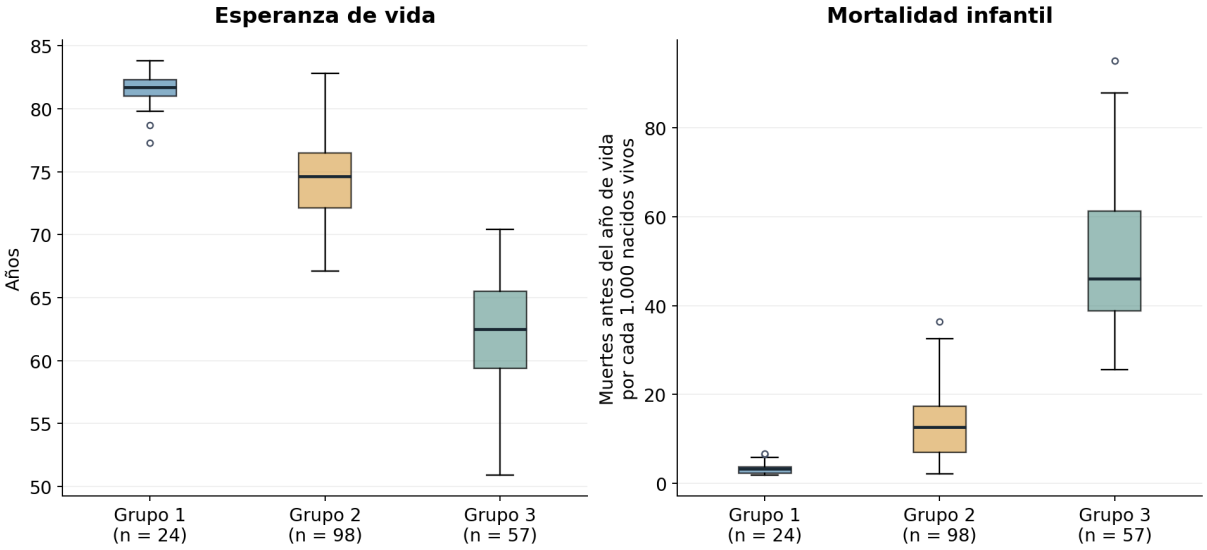
1. Utilizando el conjunto de datos “Life expectancy (Curated)”, disponible en https://ignaciorlando.github.io/datasets/data-science/Life-Expectancy-Data-Updated.csv y cuya descripción está disponible en el sitio de Kaggle:
    a. Agrupar los países utilizando el algoritmo de K-means, utilizando un valor de K dado. ¿Qué hipótesis pueden derivarse del clustering realizado? Recordar que este algoritmo sólo está definido para variables cuantitativas.
    b. Implementar un Elbow plot y estudiar diferentes variaciones de K. ¿Cuáles son los 3 agrupamientos que en principio parecen más correctos?
    c. Realizar los agrupamientos con los 3 valores de K considerados, evaluarlos, y comparar los resultados obtenidos utilizando algunas de las métricas vistas en clase. ¿Cuál es el que, según estos valores, pareciera ser el más correcto?
    d. Analizar los resultados del agrupamiento con el valor de K que mejor funcionó según el ejercicio anterior, representando las muestras en un espacio de 2 dimensiones utilizando PCA, t-SNE y UMAP, y coloreando los diferentes grupos. ¿Tienen sentido estos agrupamientos en el espacio reducido? Analizar.
    e. Establecer hipótesis según los resultados obtenidos y validarlas estadísticamente empleando los test que mejor se ajusten.
2. Utilizando el mismo conjunto de datos del ejercicio anterior:
    a. Agrupar los países utilizando el método de clustering aglomerativo, generar el dendrograma y estudiar los grupos resultantes según diferentes valores de umbral.
    b. Evaluar los clusters resultantes del inciso anterior utilizando métricas de evaluación. ¿Cuál es el valor de umbral más correcto, según dicho análisis?
    c. Repetir el estudio variando la distancia utilizada para comparar las muestras. ¿Qué grupos se identifican? ¿Qué características en común tienen estos países? Analizar gráficamente las características mediante boxplots para estudiar similitudes y diferencias entre los grupos.
    d. Repetir el mismo estudio utilizando clustering jerárquico.
3. Utilizando el conjunto de datos “ObesityDataSet_raw_and_data_sinthetic” trabajado en los prácticos 2 y 3 y 5:
    a. Agrupar los individuos utilizando clustering jerárquico, según las características relacionadas con los hábitos alimenticios (FAVC, FCVC, NCP, CAEC, CH20, CALC). Tener en cuenta que utilizar variables categóricas requiere un preprocesamiento especial (one hot encodings), y trabajar con otra función de distancia (por ejemplo, Jaccard o Hamming). Pueden encontrar los nombres de todas las distancias disponibles en: https://docs.scipy.org/doc/scipy/reference/generated/scipy.spatial.distance.pdist.html#scipy.spatial.distance.pdist. Analizar y describir los grupos formados. ¿Existen patrones claros en el consumo de alimentos o bebidas entre los diferentes grupos?

b. Agrupar a los individuos basándose en las variables relacionadas con la actividad física (FAF, SCC, TUE, MTRANS). Comparar estos grupos con la variable NObesity para analizar si existe alguna relación entre el tipo de actividad y el nivel de obesidad.
c. Establecer hipótesis según los resultados obtenidos y validarlas estadísticamente empleando los test que mejor se ajusten.

A continuación incluimos algunos ejercicios tipo parcial para que puedan hacer con papel y lápiz para prepararse mejor para el examen.

Ejercicio 1:

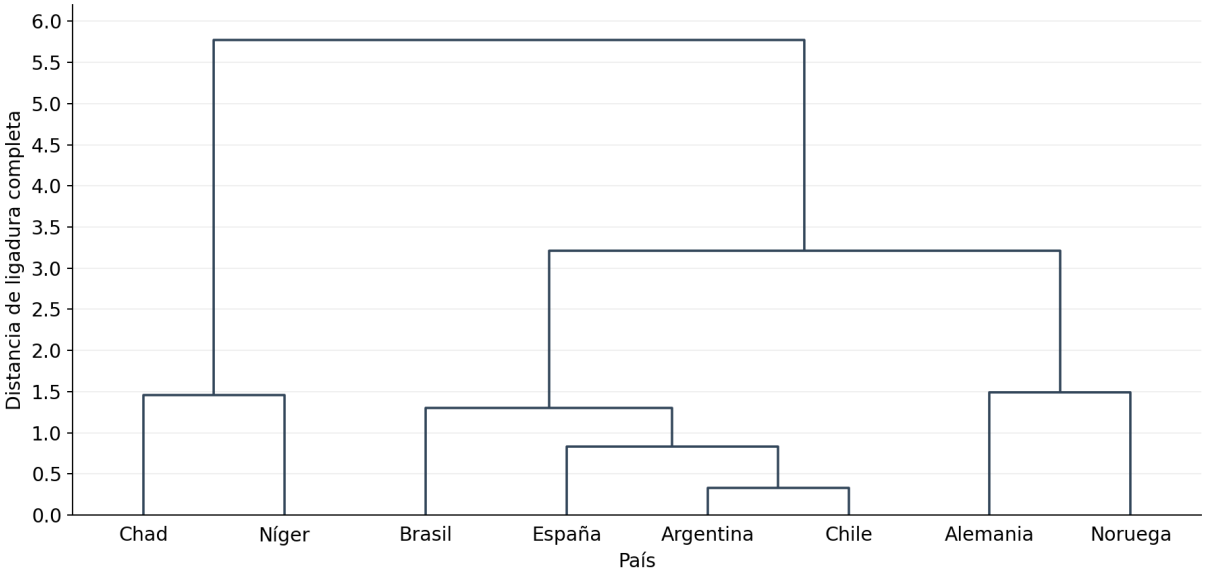
Se aplicó K-means con $k = 3$. Para los agrupamientos se emplearon cuatro variables estandarizadas: PBI per cápita, años de escolaridad, mortalidad infantil y mortalidad adulta. La esperanza de vida no se utiliza para construir los grupos. Los siguientes boxplots muestran la esperanza de vida y la mortalidad infantil de los países de cada grupo, expresadas en sus unidades originales.



a) Describa y compare los tres grupos considerando las medianas, los rangos intercuartílicos y la superposición entre distribuciones. Proponga una descripción breve para cada grupo.
b) ¿Cuál presenta mayor homogeneidad en esperanza de vida? ¿Ocurre lo mismo con la mortalidad infantil? Explique qué elementos del gráfico utiliza para responder.
c) Identifique valores atípicos. ¿Su presencia implica que esos países fueron asignados incorrectamente a un grupo? Considere que el agrupamiento se construyó utilizando varias variables.
d) Un estudiante afirma: “Como los grupos tienen diferente esperanza de vida, el algoritmo agrupó los países según esa variable”. Evalúe la afirmación considerando las variables utilizadas por K-means.
e) ¿Estos boxplots alcanzan para concluir que el agrupamiento es adecuado? Indique qué información adicional utilizaría para evaluarlo.

Ejercicio 2

Se seleccionaron ocho países del mismo conjunto. Se estandarizaron nuevamente las cuatro variables considerando solamente esos países y se aplicó clustering jerárquico aglomerativo con distancia euclídea y ligadura completa.



a) ¿Qué países se unen primero? ¿Qué representa la altura a la que ocurre esa unión?
b) Indique cuántos grupos se obtienen al realizar un corte horizontal a una altura de 2 y a una altura de 4. Enumere los países que integran cada grupo en ambos casos.
c) ¿Qué cantidad de grupos propondría explorar a partir del dendrograma? Justifique considerando los saltos entre las alturas de las uniones.
d) Explique en qué consiste la ligadura completa. ¿Cómo se interpreta la unión que ocurre aproximadamente a una altura de 3,2?

Ejercicio 3

Sobre los 179 países se aplicó K-means con distintos valores de k, manteniendo las mismas variables y el mismo preprocesamiento. Se obtuvieron los resultados de la tabla de más abajo.

a) Explique qué mide la inercia y por qué tiende a disminuir cuando aumenta k. ¿Sería correcto elegir siete grupos solamente porque presentan la menor inercia?
b) A partir de la evolución de la inercia, ¿dónde ubicaría un posible “codo”? ¿Qué valores de k propondría explorar?
c) Explique qué mide el coeficiente de silueta. ¿Qué indican los resultados sobre las particiones con dos y tres grupos frente a las restantes?
d) Seleccione una partición para continuar el análisis. ¿Las métricas permiten decidir inequívocamente entre dos y tres grupos? Indique qué información adicional consideraría.

k	**Inercia — WSS**	**Silueta media**
2	338,6	0,480
3	202,0	0,480
4	158,5	0,380
5	132,2	0,343
6	117,1	0,320
7	103,5	0,316

Ejercicio 4

Se aplicó clustering jerárquico aglomerativo sobre los mismos 179 países, utilizando distancia euclídea y tres tipos de ligadura. En todos los casos se solicitaron tres grupos.

Para este ejercicio, Dunn se calcula como el cociente entre la menor distancia entre centroides y el mayor diámetro intracluster. El diámetro es la máxima distancia entre dos observaciones de un mismo grupo.

Ligadura	**Silueta media**	**Davies–Bouldin**	**Dunn**	**Tamaños de los grupos**
Simple — *single*	0,367	0,347	0,570	177 / 1 / 1
Completa — *complete*	0,410	0,696	0,517	76 / 100 / 3
Promedio — *average*	0,474	0,680	0,646	23 / 50 / 106

a) Explique qué diferencia existe entre las tres ligaduras. Distinga la distancia entre observaciones del criterio utilizado para comparar grupos.
b) Para cada métrica, indique si se busca maximizarla o minimizarla y qué agrupamiento resulta preferido.
c) Un estudiante elige la ligadura simple porque obtiene el menor Davies–Bouldin. Evalúe esa decisión considerando las demás métricas y los tamaños de los grupos.
d) ¿Que una partición tenga grupos de tamaños muy diferentes implica necesariamente que sea incorrecta? Discuta particularmente la solución de 177 / 1 / 1.
e) Si el objetivo fuera identificar perfiles socioeconómicos y sanitarios de países, ¿qué partición elegiría para estudiar en mayor profundidad? Explique cómo complementaría las métricas con el análisis de los países y sus características.