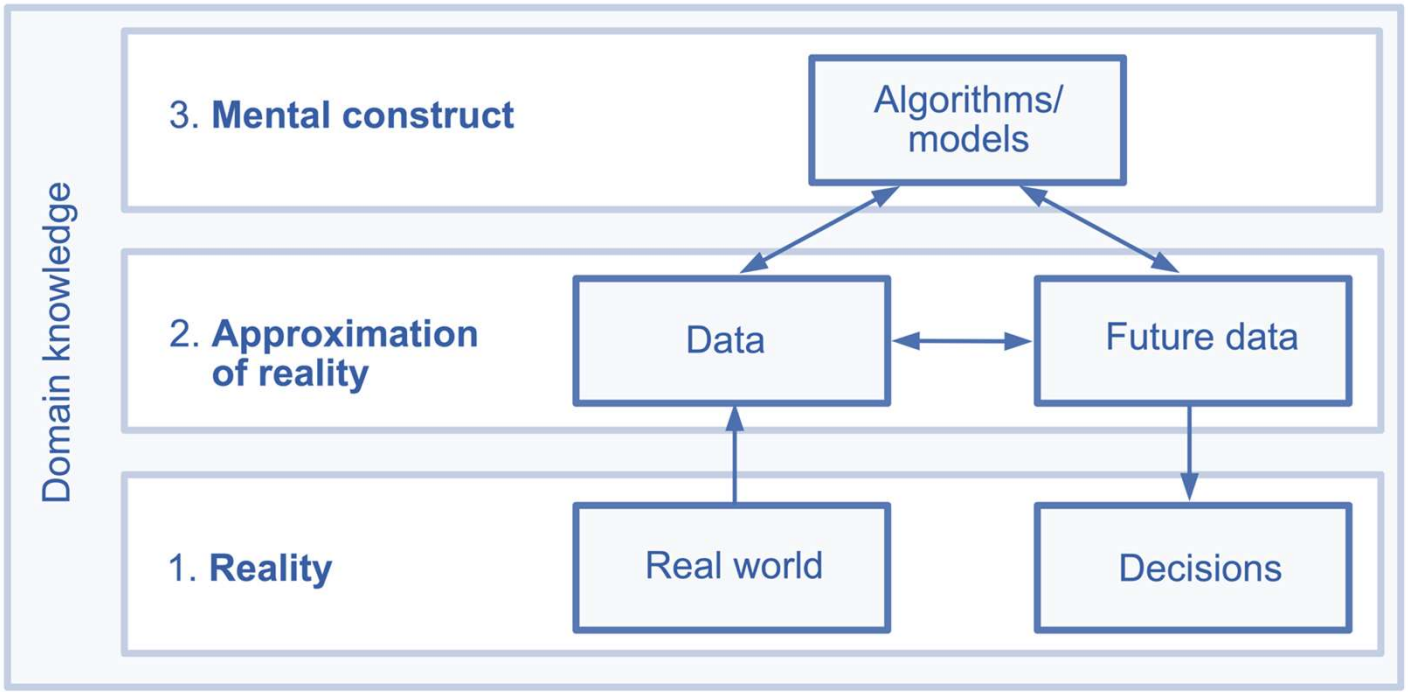
¿Qué vamos a ver hoy?

- Modelar con datos
- Modelo de regresión lineal simple
- Modelo de regresión lineal múltiple
- Modelos de regresión
- Métricas para la evaluación
- Ejemplo

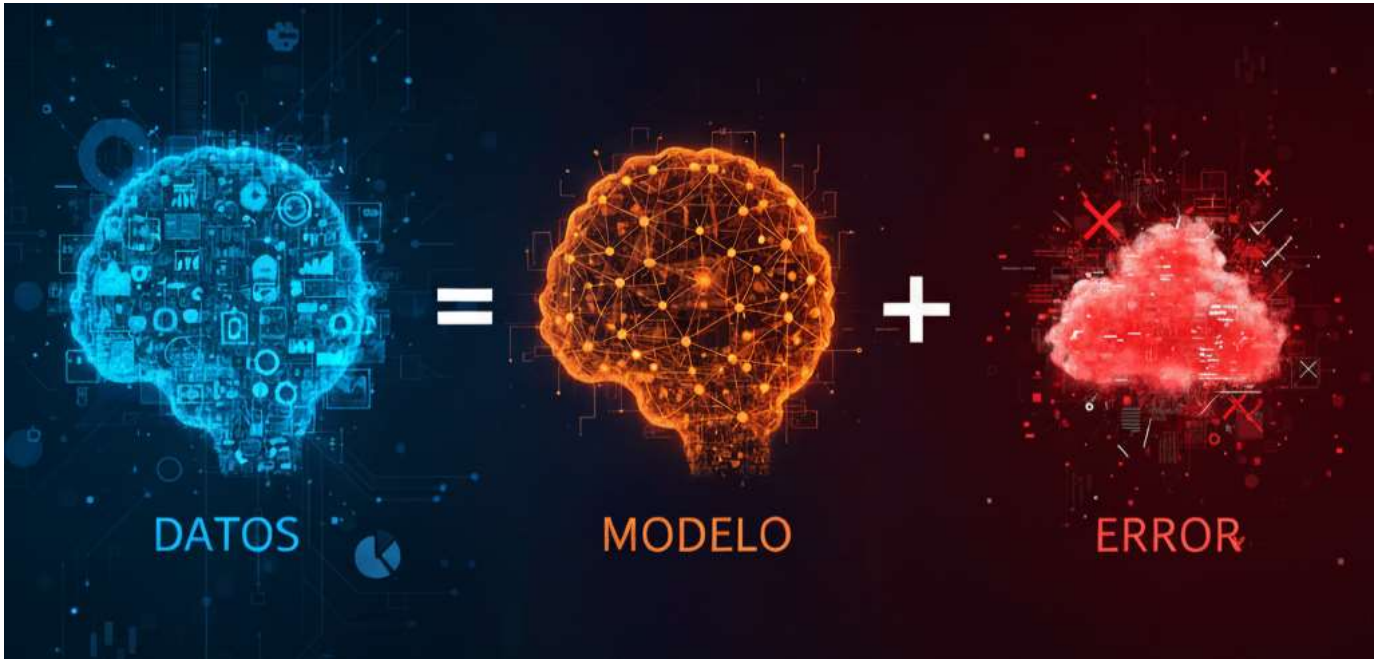


Modelar con datos



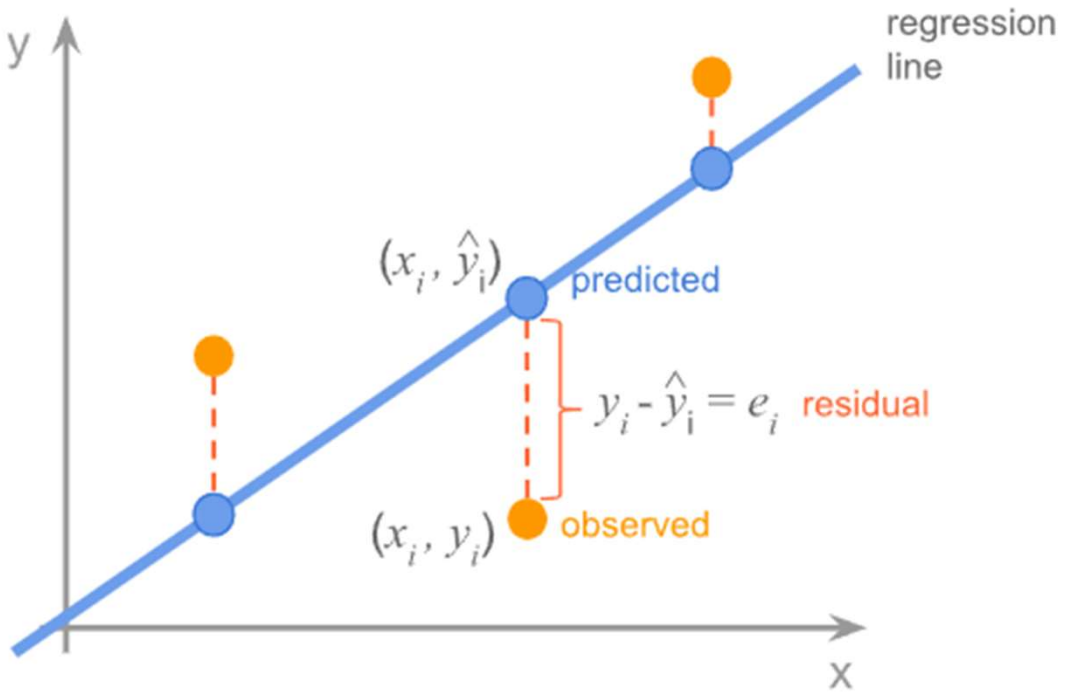
Yu, B. & Barter, R. (2024) Veridical Data Science: The Practice of Responsible Data Analysis and Decision Making (Adaptive Computation and Machine Learning series). The MIT Press

Modelar con datos

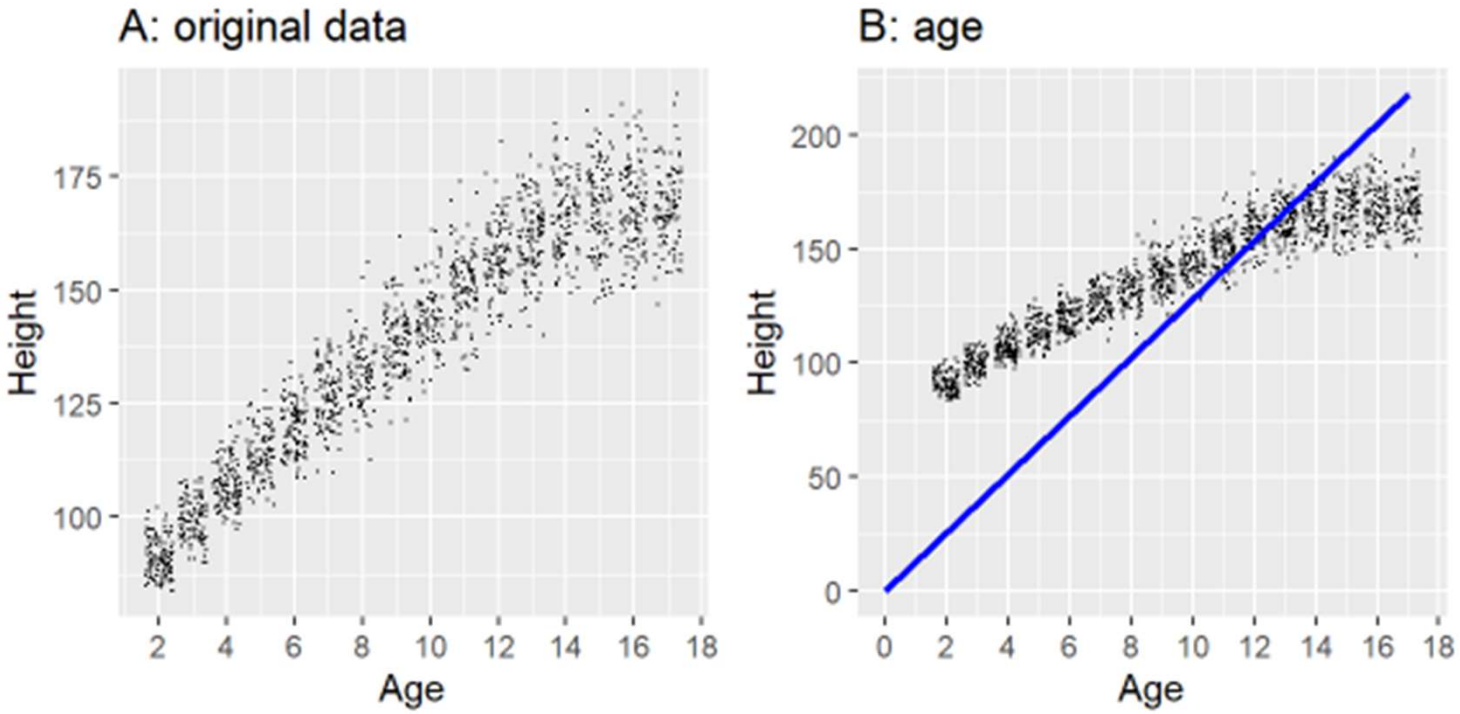


An unsophisticated forecaster uses statistics as a drunken man uses lamp posts for support rather than illumination

Datos, modelo y error



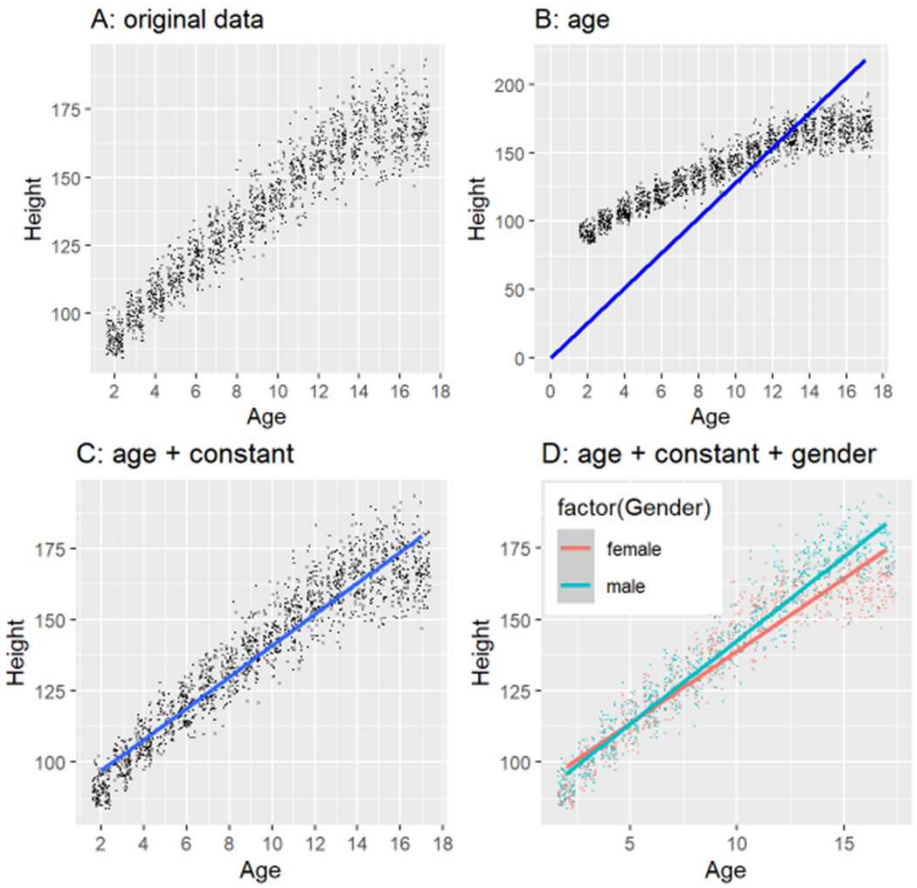
Modelar con datos

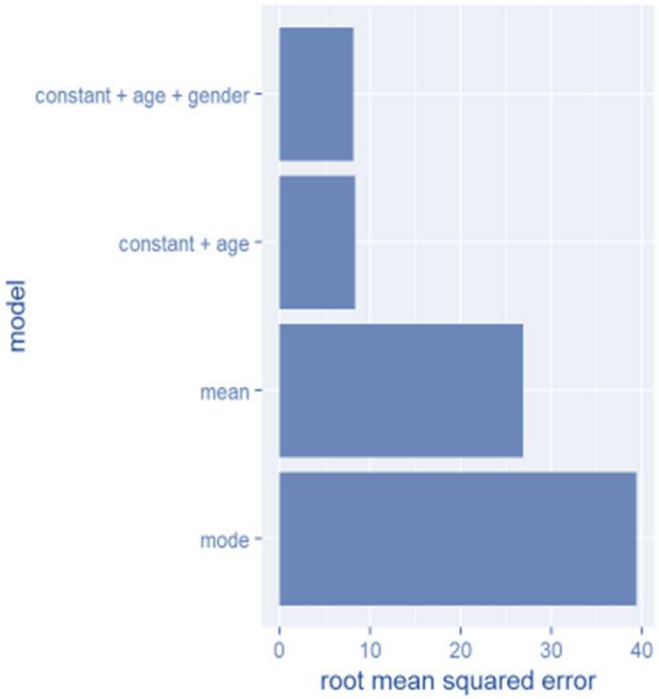


Modelar con datos



Modelar con datos





Modelo de regresión lineal

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_p x_p + \epsilon$$

y: la variable dependiente; lo que estamos tratando de predecir.

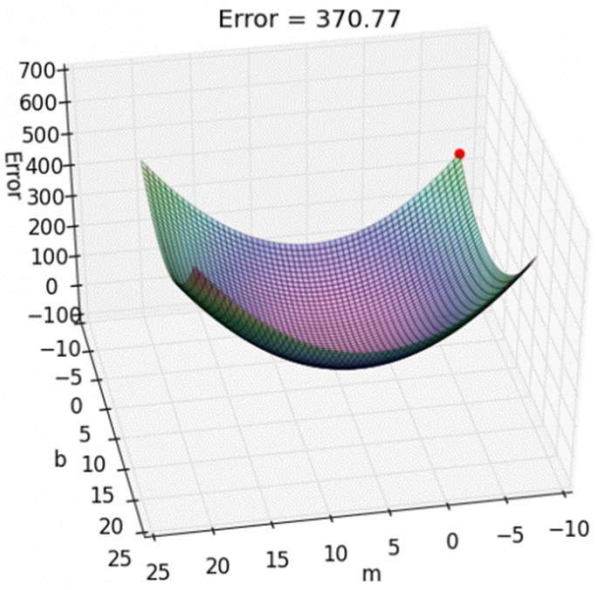
x_i las variables independientes: las características que nuestro modelo utiliza para modelar y.

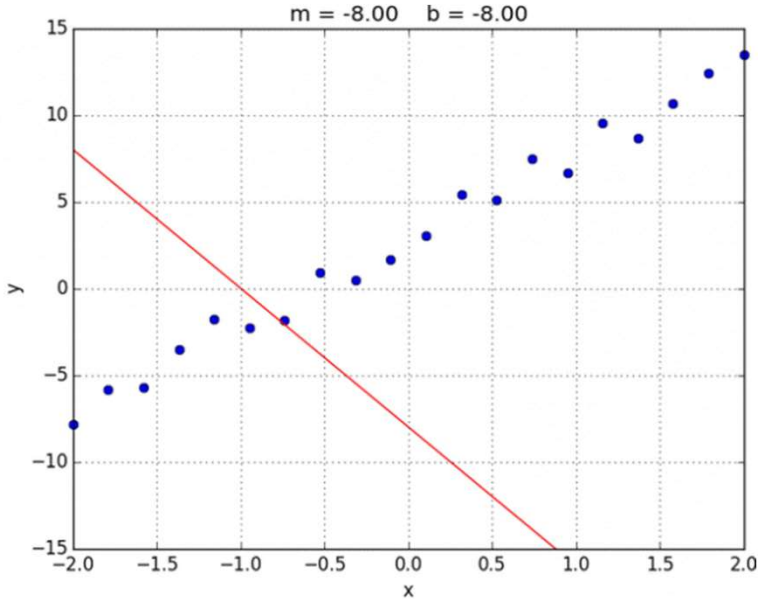
β_i: los coeficientes (también conocidos como "pesos") de nuestro modelo de regresión. Estos son los fundamentos de nuestro modelo. Son los valores que nuestro modelo “estima o aprende" durante la optimización. B_0 es llamado intercepto cuando y es el valor que adopta la variable y cuando todos los predictores son 0.

ϵ: el error irreducible en nuestro modelo. Un término que reúne todas las partes no modeladas de nuestros datos.

- ✓ 1 predictor: **Regresión lineal simple**,
- ✓ en R^n n>1(2 o más predictores) **Regresión lineal múltiple**

Regresión lineal





Fuente:
https://medium.com/@savannahar68/getting-started-with-regression-a39aca03b75f

Hipótesis del modelo de regresión

- ✓ ***Aditividad y linealidad***: El componente determinista de un modelo de regresión es una función lineal de los predictores separados: $y=\beta_0+\beta_1 x_1+...+B_p$
- ✓ ***Independencia de los errores***: los errores del modelo son independientes.
- ✓ ***Homocedasticidad***: los errores del modelo tienen varianzas iguales.
- ✓ ***Normalidad de los errores***: los errores del modelo se distribuyen normalmente.
- ✓ **Sin multicolinealidad perfecta** para los predictores
- ✓ **Parsimonia**: se refiere a la idea de que, entre dos modelos igualmente eficaces para describir un conjunto de datos, se debe elegir el modelo más simple.

¿Cómo estimo el modelo?

El desafío consiste en encontrar estimaciones de parámetros denotadas por $\hat{\beta}_0, \hat{\beta}_1, \ldots, \hat{\beta}_p$ que proporción en la “mejor” aproximación para Y :

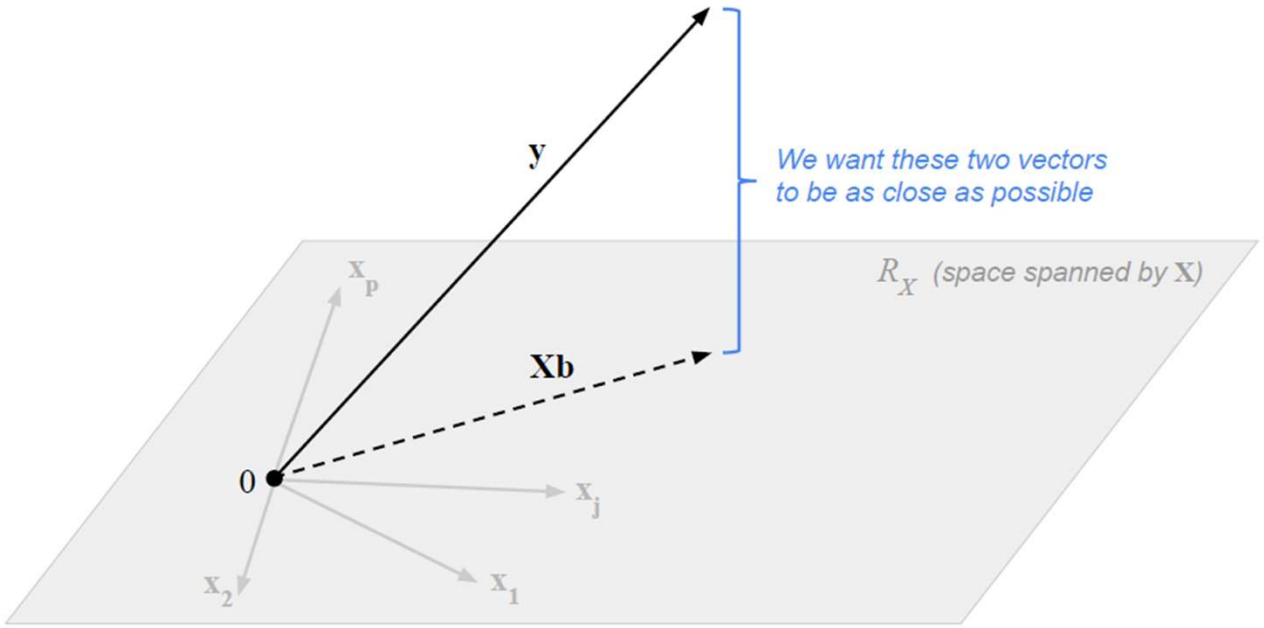
$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \ldots + \hat{\beta}_n x_n$$

La idea es elegir $\hat{\beta}_0, \hat{\beta}_1, \ldots, \hat{\beta}_p$ tal que minimice el tamaño de los residuos

$$\mathrm{e} = \mathrm{y} - \hat{\mathrm{y}} = \mathrm{y} - \mathrm{Xb}$$

El criterio universal es el de Mínimos Cuadrados Ordinarios (OLS).

Gráficamente



Estimación

Queremos minimizar los residuos para todos i: 0… n

$$e_i = y_i - \hat{y}_i$$

Los mínimos cuadrados implican minimizar la suma de cuadrados.

$$min \left\{ \sum_{i=1}^{n} e_i^2 \right\}$$

Esta suma es mejor conocida como la suma residual de cuadrados.

$$RSS = \sum_{i=1}^{n} e_i^2$$

En notación matricial

$$RSS = \mathbf{e}^\mathsf{T}\mathbf{e} = \|\mathbf{e}\|^2 = \|\mathbf{y} - \hat{\mathbf{y}}\|^2$$

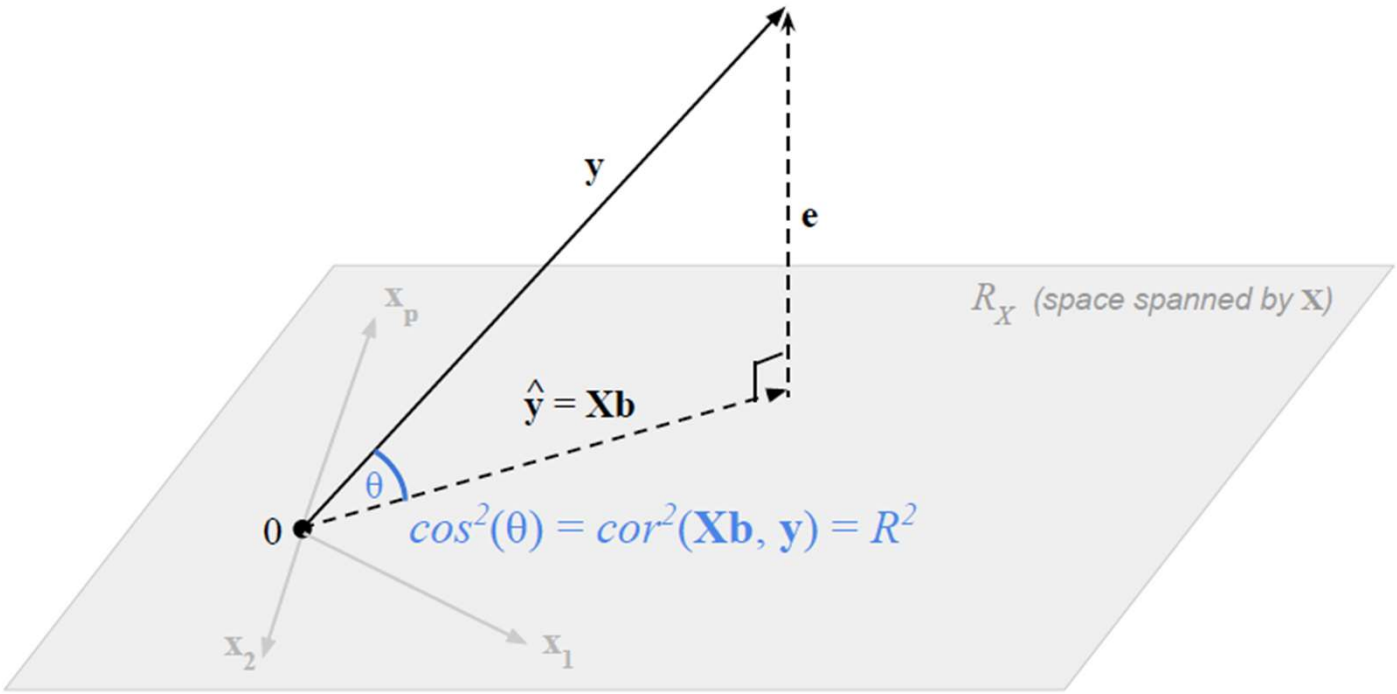
Estimación

$$RSS(\mathbf{b}) = \sum_{i=1}^{n} e_i^2 = \mathbf{e}^\mathsf{T}\mathbf{e} = (\mathbf{y} - \mathbf{X}\mathbf{b})^\mathsf{T}(\mathbf{y} - \mathbf{X}\mathbf{b})$$

$$\frac{RSS(\mathbf{b})}{\partial \mathbf{b}} = -2\mathbf{X}^\mathsf{T}\mathbf{y} + 2\mathbf{X}^\mathsf{T}\mathbf{X}\mathbf{b}$$

$$\mathbf{b} = (\mathbf{X}^\mathsf{T}\mathbf{X})^{-1}\mathbf{X}^\mathsf{T}\mathbf{y}$$

Gráficamente



Fundamentos de Inferencia: Validez y BLUE

TEOREMA Gauss-Markov: Si se cumplen las asunciones básicas, $\hat{\beta}$ es BLUE (Best Linear Unbiased Estimator) ASUNCIONES CLAVE (Para BLUE)

1. E(ε)=0
2. Homocedasticidad
3. No correlación Cov(ϵ_i, ϵ_j)=0 i<>j

Adicional (Para Tests *t* y F)

Normalidad: ε $\sim$ N(0, $\sigma^2 I$)

Varianza, Estimación del Error y Tests

- Varianza $$Var(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}^\mathsf{T}\mathbf{X})^{-1}$$
- Estimador (insesgado) $$\hat{\sigma}^2 = \frac{RSS}{n-p-1} = \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n-p-1} = s^2$$
- Test t(coef. Individual) evalúa H_0: β_J=0 $$\text{Estadístico } t = \frac{\hat{\beta}_j}{\hat{SE}(\hat{\beta}_j)}$$
- Test F(Modelo Global) evalúa H_0: $\beta_1 = \cdots = \beta_p = 0$

$$(n-p-1)\frac{\sum_{i=1}^{n}(y_i - \bar{y})^2}{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \sim F_{(1,n-p-1)}$$

Bondad del ajuste: descomposición de la varianza

$$\underbrace{\frac{1}{n}\sum(y_i)^2}_{\text{total variance}} = \underbrace{\frac{1}{n}\sum(y_i-\hat{y}_i)^2}_{\text{residual variance}} + \underbrace{\frac{1}{n}\sum(\hat{y}_i)^2}_{\text{explained variance}}$$

Bondad del ajuste: R^2

$$R^2 = \frac{cov^2(\mathbf{y}, \hat{\mathbf{y}})}{var(\mathbf{y})var(\hat{\mathbf{y}})} = \frac{var(\hat{\mathbf{y}})}{var(\mathbf{y})} = \frac{\text{explained variance}}{\text{total variance}}$$

R^2 describe la fracción de la varianza total de y que es explicada por $\hat{y}$. Minimizando el error, maximizamos R^2

El ajuste por mínimos cuadrados proporciona una combinación lineal de los predictores que tienen la máxima correlación con la variable de respuesta y.

Métricas de evaluación

- ✓ Error Absoluto Medio (Mean Absolute Error, MAE) $\mathrm{MAE} = \frac{1}{N}\sum_{i}^{N}|y^{(i)} - \hat{y}^{(i)}|$
- ✓ Error Cuadrático Medio (Mean Squared Error, MSE) $\mathrm{MSE} = \frac{1}{N}\sum_{i}^{N}\left(y^{(i)} - \hat{y}^{(i)}\right)^2$
- ✓ Raíz del Error Cuadrático Medio (Root Mean Square Error, RMSE) $\mathrm{RMSE} = \sqrt{\mathrm{MSE}}$

Métricas de Evaluación

Coeficiente de determinación (R^2)

- Indica qué tanto mejor es el modelo de regresión lineal respecto a un modelo trivial basado en tomar la media de todas las muestras. También se lo conoce como bondad del ajuste.
- Toma valores en [0, 1] (si el problema es lineal), pero puede ser negativo si es no-lineal!

Testeo de las hipótesis del modelo

Usabilidad del modelo en el dominio.

EJEMPLO

¿Puedo explicar cuanto vendo (Sale) en función de los medios en los que publicito: TV, Radio, Newspaper?

obs	TV	radio	newspaper	sales
1	230.1	37.8	69.2	22.1
2	44.5	39.3	45.1	10.4
3	17.2	45.9	69.3	9.3
4	151.5	41.3	58.5	18.5
..	…	…	…	…
200	180.8	10.8	58.4	12.9

EJEMPLO: 1^{era} parte salida

OLS Regression Results

Dep. Variable:	sales	R-squared:	0.897
Model:	OLS	Adj. R-squared:	0.896
Method:	Least Squares	F-statistic:	570.3
Date:	Sat, 25 Oct 2025	Prob (F-statistic):	1.58e-96
Time:	00:10:34	Log-Likelihood:	-386.18
No. Observations:	200	AIC:	780.4
Df Residuals:	196	BIC:	793.6
Df Model:	3		
Covariance Type:	nonrobust		

EJEMPLO: 2da parte salida

	coef	std err	t	P>|t|	[0.025	0.975]
const	2.9389	0.312	9.422	0.000	2.324	3.554
TV	0.0458	0.001	32.809	0.000	0.043	0.049
radio	0.1885	0.009	21.893	0.000	0.172	0.206
newspaper	-0.0010	0.006	-0.177	0.860	-0.013	0.011

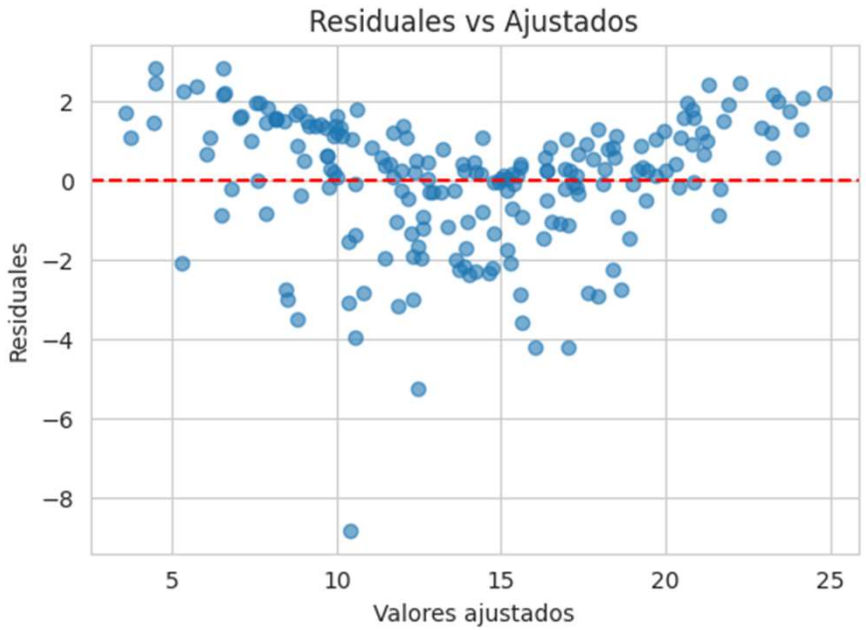
Omnibus:	60.414	Durbin-Watson:	2.084
Prob(Omnibus):	0.000	Jarque-Bera (JB):	151.241
Skew:	-1.327	Prob(JB):	1.44e-33
Kurtosis:	6.332	Cond. No.	454.

Modelo

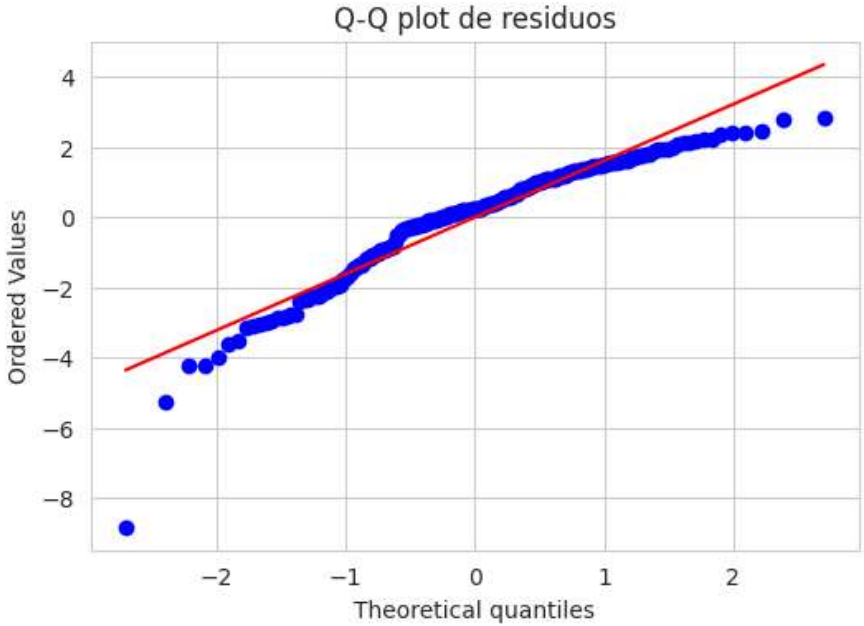
Sales = 2.9389 + 0.0458 TV + 0.1885 radio - 0.0010 newspaper



EJEMPLO: Homocedasticidad?



EJEMPLO: normalidad de error?



Shapiro-Wilk: estadístico = 0.9177, p-valor = 0.0000

Ejemplo: Multicolinealidad?

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}$$

VIF (factor de inflación de la varianza):

	variable	VIF
0	const	6.848900
1	TV	1.004611
2	radio	1.144952
3	newspaper	1.145187

Tips

- ✓ Datos limpios, sin outliers
- ✓ Revisar los rangos de la variable a predecir.
- ✓ Conocer las relaciones entre los predictores.
- ✓ La cantidad de observaciones tiene que ser al menos 20 veces la cantidad de atributos
- ✓ Modelos simples

“if you want a function to be linear, measure it at only two points”

¿Que vimos hoy?

- La regresión lineal como modelo para realizar predicciones cuando las variables son cuantitativas.
- Las métricas de evaluar la regresión.
- Evaluar las hipótesis de la regresión una vez que tengamos el modelo!
- Algunos tips empíricos



Material adicional:

- Poldrack, Russell A. (2024) Statistical Thinking for the 21st Century**.** *Cap.14* https://statsthinking21.github.io/statsthinking21-core-spanish-site/the-general-lineal-model.html#linear-regression
- Skiena, S. (2017). The manual. Data Science Design. Springer. *Cap. 9*
- Nathan, George (2021). Practical Data Science with Python. *Cap. 14 y 15*
- *Hastie (2009)The Elements of Statistical Learning Cap 3*

¿Dudas?

