Fundamentos de la Ciencia de Datos
Cursada 2026
Práctico 9: Regresión lineal

1. Utilizando el conjunto de datos "Boston House", disponible en https://ignaciorlando.github.io/datasets/housing_pandas.csv o accesible vía Sklearn:
    a. Realizar un análisis exploratorio de los datos, incluyendo un análisis de la distribución de las diferentes variables mediante gráficas y estadística descriptiva.
    b. Realizar un análisis de correlación entre la variable objetivo (precio de las viviendas) y las demás características del conjunto.
    c. Identificar un subgrupo de características factibles de poder utilizarse para la predicción de la variable respuesta, y ajustar un modelo lineal.
    d. Validar los supuestos de normalidad de los residuos del modelo utilizando los tests adecuados. ¿Se cumplen? ¿No? ¿Por qué?
    e. Volver a ajustar un modelo, esta vez utilizando todas las variables disponibles. ¿Existe una mejora en el R2? ¿Y en el AIC? ¿Se cumplen los supuestos de normalidad de los residuos en este caso? Justificar.
2. Utilizando el conjunto de datos "Life expectancy", disponible en https://ignaciorlando.github.io/datasets/data-science/Life-Expectancy-Data-Updated.csv y cuya descripción está disponible en el sitio de Kaggle:
    a. Agrupar los países utilizando algún método de clustering.
    b. ¿Podemos predecir la expectativa de vida dentro de cada grupo utilizando las características disponibles de cada país? Repetir los pasos del ejercicio 1 para comprobarlo.
3. A partir del ejemplo disponible con el California Housing Dataset, explorar potenciales correcciones que permitan recuperar un modelo lineal que cumpla con los supuestos de normalidad de los residuos.

A continuación incluimos algunos ejercicios tipo parcial para que puedan hacer con papel y lápiz para prepararse mejor para el examen.

Ejercicio 1

El conjunto *Boston Housing* contiene información de 506 zonas residenciales. Se ajustó una regresión lineal para explicar **MEDV**, la mediana del precio de las viviendas de cada zona, expresado en miles de dólares de la época, utilizando solamente estas variables:

- **RM:** cantidad promedio de habitaciones por vivienda.
- **LSTAT:** porcentaje de población de bajo nivel socioeconómico según la codificación del conjunto.
- **PTRATIO:** cantidad de estudiantes por docente.
- **AGE:** porcentaje de viviendas ocupadas por sus propietarios construidas antes de 1940.

Las variables se utilizaron en sus escalas originales. Se obtuvieron los siguientes resultados, con intervalos y pruebas calculados bajo los supuestos habituales del modelo:

Término	Coeficiente	IC del 95 %	p-valor
Ord. al origen	19,244	[11,519; 26,968]	< 0,001
RM	4,368	[3,512; 5,224]	< 0,001
LSTAT	−0,618	[−0,720; −0,517]	< 0,001
PTRATIO	−0,947	[−1,178; −0,715]	< 0,001
AGE	0,0165	[−0,0043; 0,0374]	0,120

El coeficiente de determinación fue $R^2 = 0,6802$.

a. Identificar la variable respuesta y las variables explicativas. Escribir la ecuación que permite obtener el valor estimado por el modelo.

b. Interpretar los coeficientes de RM y LSTAT, indicando las unidades correspondientes y qué significa mantener constantes las restantes variables. ¿Podés comparar directamente sus valores absolutos para determinar cuál variable es más importante?

c. Una zona presenta RM = 6,5; LSTAT = 10; PTRATIO = 18 y AGE = 60. Calcular su valor estimado. Si el valor observado es MEDV = 22, calcular el residuo e indicar si el modelo sobreestima o subestima el valor.

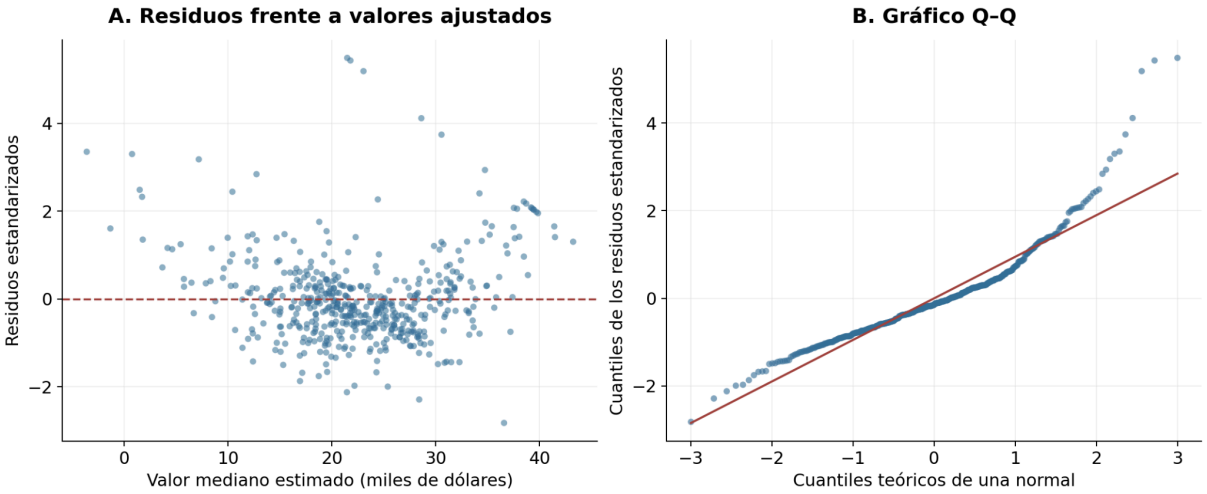
d. Si alguien concluye que “AGE no tiene ninguna relación con el valor de las viviendas porque su p-valor es mayor que 0,05”, ¿es correcto? Interpretar utilizando también el intervalo de confianza.

e. Interpretar el R^2. ¿Significa que el modelo acierta el precio del 68,02 % de las zonas? ¿Permite concluir que aumentar la cantidad de habitaciones causa el incremento indicado por el coeficiente?

Ejercicio 2

Para el modelo del ejercicio anterior se obtuvieron los siguientes gráficos y el resultado del test de Shapiro–Wilk aplicado sobre los residuos:

$$W = 0,8972, p < 0,001.$$



a. Analizar la figura A. ¿Qué ocurre con la distribución de los residuos alrededor de cero? ¿Se ve algún patrón? ¿Qué dudas generan sobre la forma del modelo y la homocedasticidad?

b. Interpretar el QQ plot en conjunto con el resultado de Shapiro–Wilk. ¿Qué puede concluirse sobre la normalidad de los errores?

c. Alguien propone aplicar Shapiro–Wilk a RM, LSTAT, PTRATIO y AGE, y descartar cualquier variable que no siga una distribución normal. ¿Este procedimiento permite verificar el supuesto de normalidad de la regresión? Justificar.

d. ¿Estos dos gráficos permiten comprobar la independencia de los errores? Considerar que las observaciones corresponden a zonas geográficas y explicar qué información adicional se necesitaría.

e. Proponer dos modificaciones del análisis que exploraría antes de aceptar el modelo. Explicar cómo evaluaría si mejoraron el diagnóstico. ¿Eliminaría automáticamente todas las observaciones con residuos grandes?

Ejercicio 3

Se ajustaron cuatro modelos mediante mínimos cuadrados ordinarios sobre las mismas 506 observaciones, manteniendo MEDV como respuesta, su escala original y un intercepto en todos los casos.

Además de las variables anteriores, se consideraron **ZN**, el porcentaje de suelo residencial destinado a lotes grandes, e **INDUS**, la proporción de superficie dedicada a actividades empresariales no minoristas.

Modelo	**Variables explicativas**	R^2	R^2 **ajustado**	**AIC**
A	RM	0,4835	0,4825	3350,2

B	RM, LSTAT, PTRATIO	0,6786	0,6767	3114,1
C	RM, LSTAT, PTRATIO, AGE	0,6802	0,6776	3113,6
D	RM, LSTAT, PTRATIO, AGE, ZN, INDUS	0,6804	0,6766	3117,3

a. Describir cómo cambia el R^2 al agregar variables. ¿Alcanza el incremento de ese valor para justificar la incorporación de nuevos predictores? ¿Por qué=

b. Explicar qué aporta el R^2 ajustado respecto del R^2. Utilizar la comparación entre C y D para fundamentar la respuesta.

c. ¿Qué información incorpora el AIC en este contexto? ¿Qué información nos aportar sobre el ajuste y la complejidad del modelo?

d. Comparar B y C considerando las métricas y el resultado del coeficiente de AGE del ejercicio 1. ¿La diferencia observada obliga a elegir C? Justificar con qué modelo te quedarías.

Ejercicio 4

Se utiliza el conjunto *Life expectancy (Curated)*, conservando los 179 países con registros de 2015.

Primero se aplicó K-means con tres grupos sobre PBI per cápita, escolaridad, mortalidad infantil y mortalidad adulta, previamente estandarizados, sin incluir la esperanza de vida en el agrupamiento. Luego se ajustó una regresión lineal simple para explicar la esperanza de vida en función de los años de escolaridad: una utilizando todos los países y otra dentro de cada grupo. Las regresiones utilizan las unidades originales.

Los resultados se calcularon sobre las mismas observaciones utilizadas para ajustar cada modelo:

Modelo	**Países**	**Coeficiente de escolaridad**	R^2	**RMSE, en años**
Global	179	1,911	0,5896	5,00
Grupo 1	24	0,282	0,0397	1,34
Grupo 2	98	0,335	0,0400	3,21
Grupo 3	57	0,402	0,0236	4,75

a. Interpretar el coeficiente de escolaridad del modelo global y compárelo con los coeficientes de los modelos por grupo. ¿Qué precauciones tendrías antes de interpretar esa asociación como un efecto causal?

b. Alguien afirma: “Separar los países en grupos empeoró necesariamente las predicciones porque todos los R^2 disminuyeron”. Evaluar esa conclusión considerando también el RMSE y la variabilidad de la respuesta dentro de cada grupo.

c. Otro estudiante sostiene que el modelo del grupo 1 es el mejor porque tiene el menor RMSE. ¿Es suficiente esa comparación? Considerar que los modelos se evaluaron sobre conjuntos de países diferentes?

d. En el grupo 1, la escolaridad observada varía entre 9,8 y 14,1 años. Se propone utilizar su regresión para un país con cuatro años de escolaridad. ¿Qué problema presenta esa estimación? ¿Qué debería verificarse para decidir qué modelo aplicar?

e. ¿Qué diagnósticos realizarías sobre cada regresión antes de utilizar sus coeficientes o predicciones? Explicar por qué los supuestos deberían examinarse nuevamente dentro de cada grupo.