

**Fundamentos de la Ciencia de Datos**  
**Cursada 2026**  
**Práctico Especial**

**Ayudante Asignado:**

Duilio Deangeli

**Enunciado:**

Realizar un análisis detallado del conjunto de datos [Global Food & Nutrition Database 2026 – Health Scores & Allergens](#) que incluya:

1. Un **análisis exploratorio inicial** de la base, investigando con recursos online el (posible) origen de los datos, caracterizando sus atributos y describiendo su comportamiento, distribución de variables, presencia de outliers, valores nulos y demás particularidades que crea de relevancia para el análisis.
2. La **implementación de operaciones de limpieza de la base** (si fuera necesario), detallando las acciones correctivas implementadas y justificando el por qué de cada una de ellas.
3. El **planteo de 3 hipótesis** que resumen de interés de acuerdo a los atributos del conjunto, justificando el porqué del planteo utilizando información del dominio.
  - a. Una univariada
  - b. Una bivariada
  - c. Una multivariada
4. **La validación de las 3 hipótesis planteadas, y de las 3 que incluimos a continuación:**
  - a) La proporción de productos catalogados como "altos en grasas saturadas" (más de 5 g de grasa saturada por cada 100 g de producto) en la población de referencia es superior al 25%.
  - b) El grado de procesamiento industrial de un alimento está asociado con la calificación nutricional Nutri-Score que recibe, de manera que los productos más procesados presentan calificaciones más desfavorables.
  - c) El grado de procesamiento industrial (NOVA), la categoría del producto y la cantidad de alérgenos declarados explican conjuntamente la probabilidad de que un producto reciba una calificación Nutri-Score desfavorable (D/E), sin utilizar directamente su composición nutricional.

Debe realizarse utilizando las técnicas apropiadas, según se vieron en clase. Justificar las técnicas escogidas, detallar los pasos realizados para la

evaluación y discutir los resultados obtenidos tras la aplicación de las técnicas, confirmando o no la validez de la hipótesis.

## Grupos

El trabajo se realizará en grupos de no más de 3 personas, que deberán registrarse utilizando el formulario disponible en el Moodle de la materia. Aquellas personas que no cuentan con compañeros/as de grupo serán asignados/as a otros por la cátedra, sin permitirse cambios una vez asignados.

## Entregables y formato de la entrega:

La entrega se realizará mediante **Github** (<https://www.github.com>), compartiendo con la cátedra **un link a un repositorio** que deberá incluir:

- **Una única notebook de Jupyter** que implemente todos los requerimientos del trabajo, organizada en secciones.
- **Un informe** que incluya los principales hallazgos y conclusiones a las que arribaron con el análisis de los datos, sin límite de páginas. Pueden usar [este template](#) como guía.
- Un **archivo requirements.txt** que permita reconstruir el ambiente de PIP asociado al código.
- Un **archivo README.md** con las instrucciones de ejecución, lo suficientemente detalladas como para asegurar que el código puede correr localmente.
- **Incluir el archivo de datos en el repositorio.**

## Fechas importantes:

- **Clases de consulta del trabajo:**
  - Todas las clases prácticas.
  - **Jueves 3 de noviembre (exclusiva para parcial y TPE)**
- **Entrega del trabajo: Martes 10 de noviembre, hasta las 23:59 hs.**
- **Devolución inicial (indicando si es necesaria reentrega o no): Martes 17 de noviembre.**
- **Defensa oral del trabajo:** a determinarse durante la semana del 23/11 al 27/11, coordinando con el ayudante asignado.

## Requisitos de la entrega y aprobación:

- El código debe ser 100% ejecutable. Si no puede ejecutarse, se penalizará en la nota y/o se solicitará reentrega.

- La notebook debe incluir secciones y estar organizada de una forma cómoda y entendible. Esas secciones deben referenciarse explícitamente en el informe, dado que se utilizarán como guía para realizar preguntas específicas sobre el código durante la evaluación oral del trabajo.
- La ausencia de alguno de los entregables será penalizada sobre la nota.
- La defensa del trabajo se realizará de manera grupal y presencial, pero la nota será individual, asignada a cada alumno del grupo según las respuestas que haya brindado durante la misma.

### Algunas recomendaciones:

- Les recomendamos buscar [videos en youtube](#) o [tutoriales online](#) para estudiar cómo se manejan repositorios en Github.
- Usen Github solamente para empaquetar la entrega, dado que van a trabajar con Jupyter notebooks, y [suele ser complejo trabajar colaborativamente con ellos](#).
- No entregar notebooks con experimentos descartados ni pruebas no realizadas. La notebook que entreguen debe contener únicamente lo que se solicita en el trabajo, y estar limpia, sin comentarios o borradores.
- Ordenar la notebook de forma cómoda para la lectura y consistente con la organización del informe, para facilitar el análisis y la corrección.

Para que se organicen mejor y hagan buen uso del tiempo, les dejamos un cronograma ordenado de actividades que podrían seguir para llevar el trabajo a buen puerto, a partir de la semana de lanzamiento del trabajo:

| Semana | Actividad                                                                                          |
|--------|----------------------------------------------------------------------------------------------------|
| 1      | Exploración inicial de la base y planteo de hipótesis univariadas y bivariadas.                    |
| 2      | Apertura de la base, análisis preliminar, limpieza.                                                |
| 3      | Planteo e implementación de pruebas para las primeras cuatro hipótesis (univariadas y bivariadas). |
| 4      | Documentación en informe y prueba de Github                                                        |
| 5      | Planteo de hipótesis multivariadas e implementación de las pruebas correspondientes.               |
| 6      | Actualización del informe y entrega                                                                |